

Проектирование БД

- Проблема представления предметной области
- Логическое проектирование
- Проблема плохого проектирования:
 - возможность записи не валидных данных
 - возможность потери информации (нет нужных связей)
 - отсутствие необходимой информации (забыли то, что было нужно)

Стадии проектирования БД

- Анализ требования предметной области
 - Составление USE CASE (чего они хотят и что они делают)
 - Аналитический процесс с участием stakeholders (владельцев, экспертов домена)
 - Концептуальная схема БД (схема данных, схема внешней системы)
- Логическое моделирование данных предметной области
 - Детализирует концептуальную модель БД (внутренние и внешние системы)
 - Разные источники включают разные компоненты в логическую модель БД (процессы, таблицы)
 - Полностью описывает все ключи (нужные и ненужные)
 - Полностью определяет типы данных (безотносительно конкретной СУБД)
 - Полностью описывает все логические ограничения (спорно)
 - Нормализация отношений обычно максимум до 3НФ
- Физическое проектирование и нормализация
 - Выбирается конкретная СУБД
 - Определяются типы данных
 - Определяются индексы
 - Могут определяться представления (views)
 - Определяются ограничения на доступ (security)

ER Diagrams

- dbdiagram.io
- pgModeler
- SQL Power Architect
- MySQL Workbench
- Oracle SQL Developer Data Modeler

Базовые советы

- Таблица: объект, событие, абстракция
- Поле (колонка): свойство объекта
- Запись (строка): совокупность полей
- Значения в каждом поле по отдельности не должны содержать не валидных данных
- Значения в совокупности полей должны быть непротиворечивыми

Плохие практики

- Игнорирование нормализации - избыточность данных
- Отсутствие стандартов именования на проекте
- Одна таблица для разных по смыслу данных (каждая таблица должна отражать некий объект)
- Наплевательское отношение к актуальности репрезентации данных (домен меняется - это живой механизм!)
- Поле, содержащие более 1 логической части (full_name)
- Поле, содержащие более 1 значения (массив, когда не надо)
- Вычисляемое поле (когда не надо, полная зарплата за все время работы)
- Неправильно выбранные первичные ключи (ИНН - плохой РК)
- Избегайте композитных РК (можер приводить к деградации производительности)\
- В идеале, в таблице кроме суррогатного ключа, должен быть и натуральный
- Правила иногда можно нарушать! Вычисляемое поле даёт performance boost? Делаем вычисляемое поле ...

Нормальная форма (НФ)

Нормальная форма - это форма, в которой все логические ограничения принадлежат к одному типу.

Нормальная форма (НФ) - свойство отношения, характеризующее его с точки зрения избыточности.

Нормализация - процесс минимизации избыточности отношения (приведение к НФ).

1НФ

- Нет дубликатов
- Все атрибутов простых типов данных
- Все значения скалярные

author_name	book_title
Лев Толстой	Война и мир, Анна Каренина, Старик в церкви
Фёдор Достоевский	Игрок, Идиот, Бесы

author	book_title
Лев Толстой	Война и мир
Лев Толстой	Анна Каренина
Лев Толстой	Старик в церкви
Фёдор Достоевский	Игрок
Фёдор Достоевский	Идиот
Фёдор Достоевский	Бесы

2НФ

- Таблица удовлетворяет 1НФ
- Есть первичный ключ

author_id	book_id	author_name	book_title
1	1	Лев Толстой	Война и мир
1	2	Лев Толстой	Анна Каренина
1	3	Лев Толстой	Старик в церкви
2	4	Фёдор Достоевский	Игрок
2	5	Фёдор Достоевский	Идиот
2	6	Фёдор Достоевский	Бесы

- Все атрибуты (поля) описывают первичный ключ целиком, а не лишь его часть

author_id	book_id	author_name	book_title	publisher_title	publisher_contact
1	1	Лев Толстой	Война и мир	Альпина	9031112233
1	2	Лев Толстой	Анна Каренина	ЦентрИздат	9032223344
1	3	Лев Толстой	Старик в церкви	Питер	9033334455
2	4	Фёдор Достоевский	Игрок	ЦентрИздат	9032223344
2	5	Фёдор Достоевский	Идиот	ЦентрИздат	9032223344
2	6	Фёдор Достоевский	Бесы	Альпина	9031112233

author_id	author_name
1	Лев Толстой
2	Фёдор Достоевский

book_id	book_title	publisher_title	publisher_contact
1	Война и мир	Альпина	9031112233
2	Анна Каренина	ЦентрИздат	9032223344
3	Старик в церкви	Питер	9033334455
4	Игрок	ЦентрИздат	9032223344
5	Идиот	ЦентрИздат	9032223344
6	Бесы	Альпина	9031112233

author_id	book_id
1	1
1	2
1	3
2	4
2	5
2	6

3НФ

- Таблица удовлетворяет 2НФ
- Нет зависимостей одних неключевых атрибутов от других (все атрибуты зависят только от первичного ключа)

book_id	book_title	publisher_title	publisher_contact
1	Война и мир	Альпина	9031112233
2	Анна Каренина	ЦентрИздат	9032223344
3	Старик в церкви	Питер	9033334455
4	Игрок	ЦентрИздат	9032223344
5	Идиот	ЦентрИздат	9032223344
6	Бесы	Альпина	9031112233

publisher_id	title	contact
1	Альпина	9031112233
2	ЦентрИздат	9032223344
3	Питер	9033334455

book_id	book_title	publisher_id
1	Война и мир	1
2	Анна Каренина	2
3	Старик в церкви	3
4	Игрок	2

book_id	book_title	publisher_id
5	Идиот	2
6	Бесы	1

4НФ

- Таблица удовлетворяет 3НФ
- Отсутствуют ненормализованные многозначные зависимости.
 - Многозначная зависимость возникает, когда одна колонка в таблице связана с множеством значений другой колонки, и эти значения независимы друг от друга.

book_id	book_title	publisher_id	language
1	Война и мир	1	Русский
1	Война и мир	1	Английский
1	Война и мир	2	Русский
1	Война и мир	2	Английский
2	Анна Каренина	2	Русский
2	Анна Каренина	2	Французский

Здесь видно, что таблица содержит дублирующиеся данные из-за наличия многозначной зависимости: один и тот же book_id связан как с несколькими publisher_id, так и с несколькими language. Чтобы привести таблицу к 4НФ, нужно разделить данные на две отдельные таблицы, устраняя многозначную зависимость.

Приведение к 4НФ

- Таблица для соответствий "книга — издатель"

book_id	book_title	publisher_id
1	Война и мир	1
1	Война и мир	2
2	Анна Каренина	2

- Таблица для соответствий "книга — язык"

book_id	book_title	language
1	Война и мир	Русский
1	Война и мир	Английский
2	Анна Каренина	Русский
2	Анна Каренина	Французский